

Previsão de atrasos aéreos com Redes Neurais Recorrentes

SimpleRNN × LSTM × GRU com dados de voos da ANAC

Trabalho Prático de Deep Learning - Redes Recorrentes

Integrantes:

- Cláudio Antônio de Araújo - claudio.araujo@estudantes.ifg.edu.br
- José Allan Kardec Gonçalves - joseallan@gmail.com

Prever o atraso médio da próxima hora

Tarefa
Regressão em série temporal horária

Entrada
Últimas 24 h, com 7 variáveis por hora

Saída
Atraso médio das partidas (min) na hora t

Utilidade
Remanejar aeronaves, tripulações e portões antes que o atraso se propague

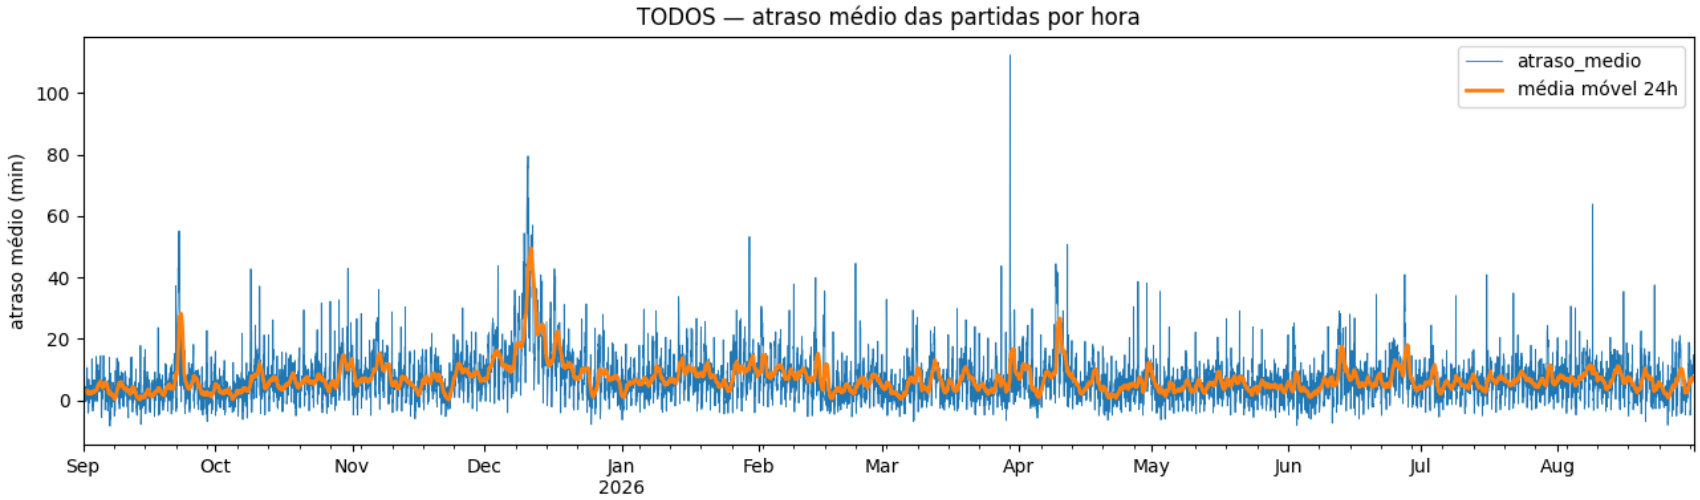


Um ano de voos do VRA, agregados hora a hora

1 milhão
de voos (set/2025 a ago/2026)

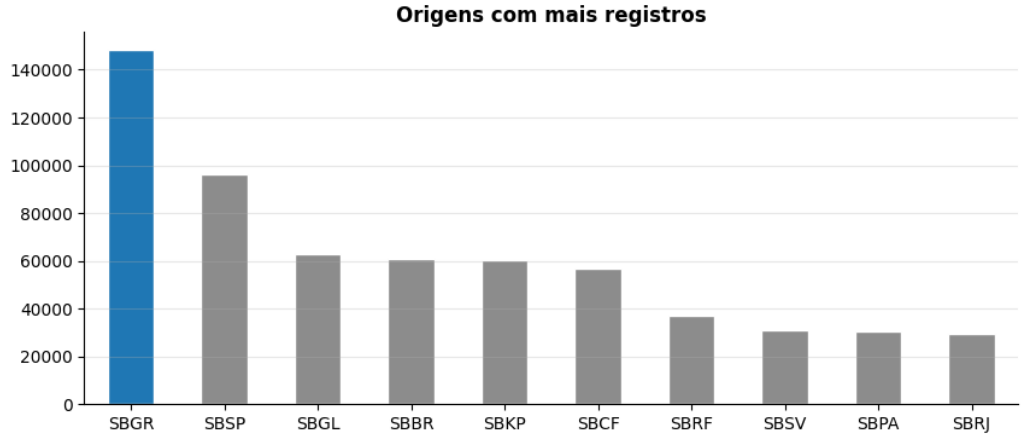
8.760
horas na série temporal
365 dias x 24h

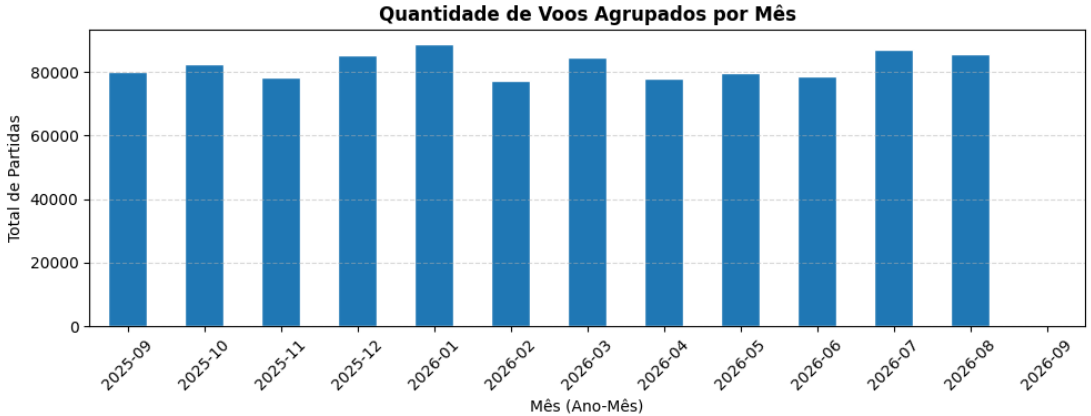
29,9 mil
voos cancelados



https://dados.gov.br/dados/conjuntos-dados/dadosabertos-areas-de-atuacao-voos-e-operacoes-aereas-voo-regular-ativo-vra

Dados





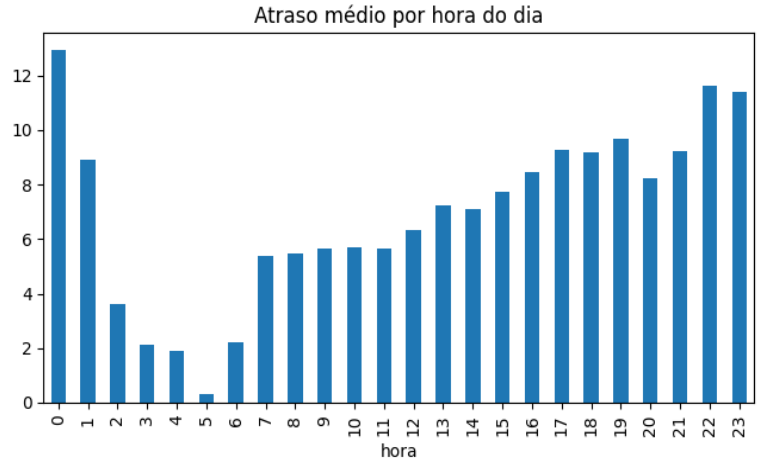
https://dados.gov.br/dados/conjuntos-dados/dadosabertos-areas-de-atuacao-voos-e-operacoes-aereas-voo-regular-ativo-vra

Três decisões de pré-processamento

Limite de extremos
Atrasos limitados a [-60, 300] min para que anomalias raras não dominem a média da hora

Sem vazamento de dados
StandardScaler ajustado só no treino e aplicado à validação e ao teste

Hora do dia cíclica
Seno e cosseno da hora: 23h e 0h ficam vizinhas para a rede

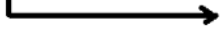


O atraso cresce ao longo do dia, à medida que atrasos anteriores se propagam, e é mínimo de madrugada.

Exemplo de Janela 24h

feature	significado
`n_voos`	partidas previstas na hora
`atraso_medio`	atraso médio dos voos realizados (**é o que queremos prever**)
`pct_atrasados`	fração com mais de 15 min de atraso
`n_cancel`	voos cancelados
`hora_sin`, `hora_cos`	hora do dia em forma circular (23h fica perto de 0h)
`fim_semana`	sábado ou domingo

	n_voos	atraso_medio	pct_atrasados	n_cancel	hora_sin	hora_cos	fim_semana
2025-09-01 00:00:00	19	20.052632	0.210526	0	0.000000e+00	1.000000e+00	0
2025-09-01 01:00:00	26	1.260870	0.043478	3	2.588190e-01	9.659258e-01	0
2025-09-01 02:00:00	52	1.884615	0.115385	0	5.000000e-01	8.660254e-01	0
2025-09-01 03:00:00	48	-5.437500	0.020833	0	7.071068e-01	7.071068e-01	0
2025-09-01 04:00:00	49	-2.791667	0.062500	1	8.660254e-01	5.000000e-01	0
2025-09-01 05:00:00	92	-4.641304	0.054348	0	9.659258e-01	2.588190e-01	0
2025-09-01 06:00:00	124	3.247934	0.082645	3	1.000000e+00	6.123234e-17	0
2025-09-01 07:00:00	104	7.718447	0.067961	1	9.659258e-01	-2.588190e-01	0
2025-09-01 08:00:00	176	4.976879	0.109827	3	8.660254e-01	-5.000000e-01	0
2025-09-01 09:00:00	160	0.602564	0.070513	4	7.071068e-01	-7.071068e-01	0
2025-09-01 10:00:00	128	0.609375	0.117188	0	5.000000e-01	-8.660254e-01	0
2025-09-01 11:00:00	143	1.285714	0.128571	3	2.588190e-01	-9.659258e-01	0
2025-09-01 12:00:00	159	4.159236	0.152866	2	1.224647e-16	-1.000000e+00	0
2025-09-01 13:00:00	126	4.370968	0.145161	2	-2.588190e-01	-9.659258e-01	0
2025-09-01 14:00:00	150	2.140000	0.140000	0	-5.000000e-01	-8.660254e-01	0
2025-09-01 15:00:00	145	-0.486111	0.083333	1	-7.071068e-01	-7.071068e-01	0
2025-09-01 16:00:00	117	4.469565	0.121739	2	-8.660254e-01	-5.000000e-01	0
2025-09-01 17:00:00	179	1.657303	0.146067	1	-9.659258e-01	-2.588190e-01	0
2025-09-01 18:00:00	147	0.732394	0.098592	5	-1.000000e+00	-1.836970e-16	0
2025-09-01 19:00:00	123	0.065041	0.130081	0	-9.659258e-01	2.588190e-01	0
2025-09-01 20:00:00	117	3.931624	0.128205	0	-8.660254e-01	5.000000e-01	0
2025-09-01 21:00:00	121	5.136752	0.153846	4	-7.071068e-01	7.071068e-01	0
2025-09-01 22:00:00	102	10.623762	0.217822	1	-5.000000e-01	8.660254e-01	0
2025-09-01 23:00:00	95	7.223404	0.202128	1	-2.588190e-01	9.659258e-01	0

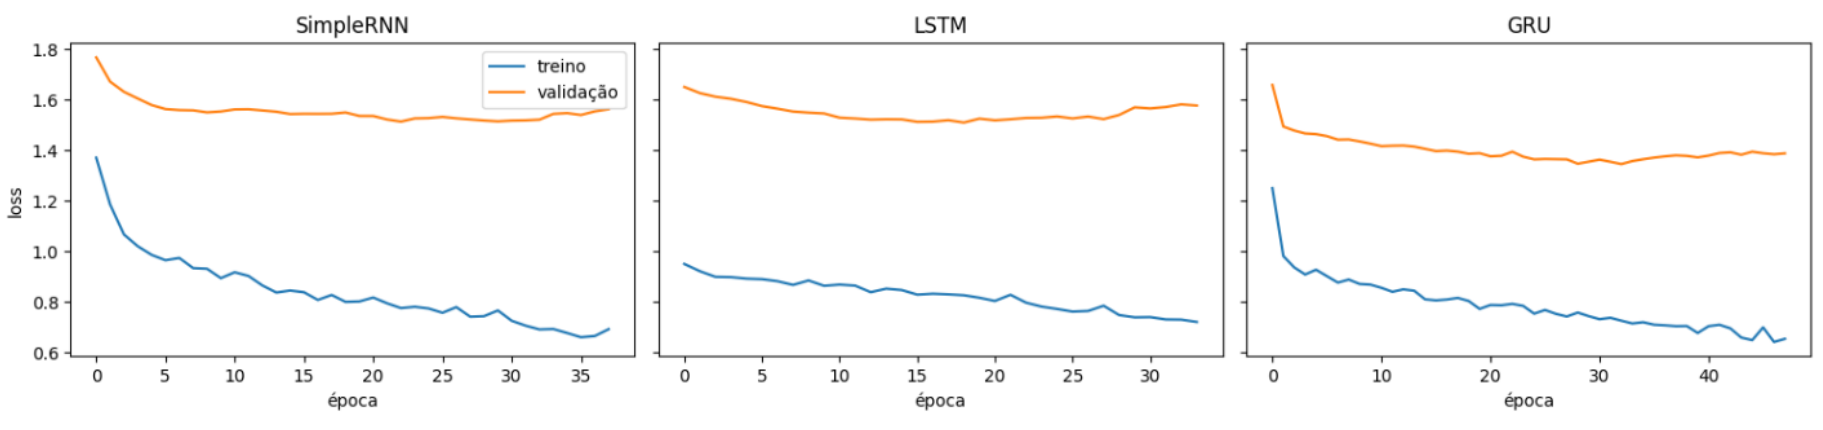


Nossa Primeira Rede

Nossa Primeira Rede Falhou ☹

- Apenas meses de 01 e 02/2026
- Apenas Guarulhos
- Janela de 24h

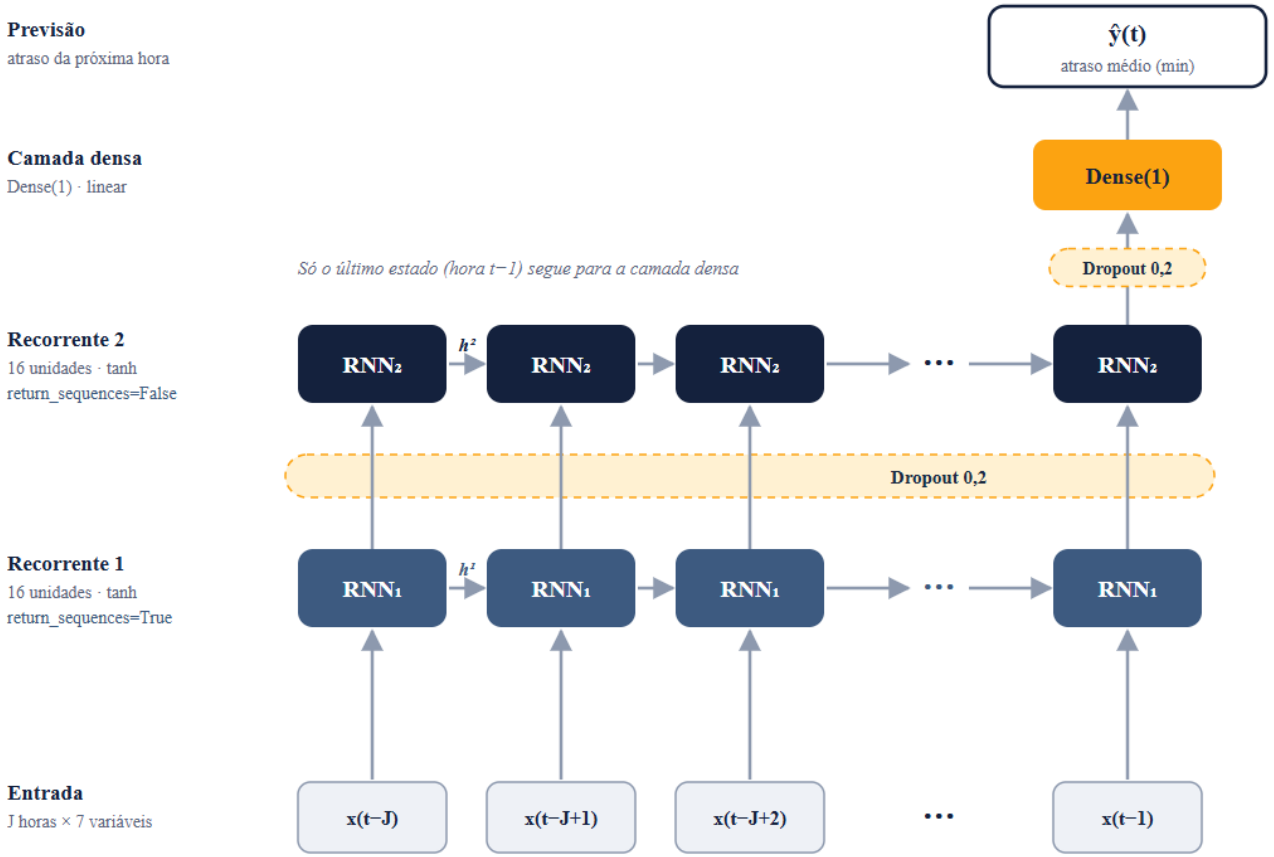
Por que falhou?



https://colab.research.google.com/drive/1B1BYDwXB1Wsrxw2zQsSkqUQ5oVHhXiy2#scrollTo=c016

Nossa Segunda Rede

Arquitetura da Rede



Arquitetura da Rede

```
# Reconstrói o modelo com a largura da janela atual
camada = {"SimpleRNN": layers.SimpleRNN, "LSTM": layers.LSTM, "GRU": layers.GRU}[tipo]

opt = keras.optimizers.Adam(learning_rate=0.003)
modelo = keras.Sequential()

modelo.add(layers.Input(shape=(janela, len(FEATURES))))
# Correção: a primeira camada recorrente deve retornar sequências se houver outra depois
modelo.add(camada(16, activation='tanh', kernel_initializer='random_uniform', return_sequences=True, use_bias=True))
modelo.add(layers.Dropout(0.2))

# A última camada recorrente antes da camada Dense não precisa retornar sequências (False)
modelo.add(camada(16, activation='tanh', kernel_initializer='random_uniform', return_sequences=False, use_bias=True))
modelo.add(layers.Dropout(0.2))

modelo.add(layers.Dense(1, activation='linear', use_bias=True))
modelo.compile(loss='mean_squared_error', optimizer=opt, metrics=["mae"])
modelo.summary()

momento_parar = keras.callbacks.EarlyStopping(monitor="val_loss", patience=20, restore_best_weights=True)

hist = modelo.fit(X_tr, y_tr, validation_data=(X_va, y_va), epochs=100, batch_size=32, callbacks=[momento_parar], verbose=DEBUG)
```

Divisão temporal e três arquiteturas recorrentes

Treino · 60%	Validação · 20%	Teste · 20%
set/2025 – abr/2026	abr – jun/2026	jun – ago/2026

Divisão cronológica, sem embaralhamento: o modelo nunca vê o futuro.

SimpleRNN

Treinando modelo SimpleRNN com janela 24...
Model: "sequential_62"

Layer (type)	Output Shape	Param #
simple_rnn_35 (SimpleRNN)	(None, 24, 48)	2,688
dropout_104 (Dropout)	(None, 24, 48)	0
simple_rnn_36 (SimpleRNN)	(None, 48)	4,656
dropout_105 (Dropout)	(None, 48)	0
dense_62 (Dense)	(None, 1)	49

Total params: 7,393 (28.88 KB)
Trainable params: 7,393 (28.88 KB)
Non-trainable params: 0 (0.00 B)

LSTM

Treinando modelo LSTM com janela 24...
Model: "sequential_63"

Layer (type)	Output Shape	Param #
lstm_37 (LSTM)	(None, 24, 48)	10,752
dropout_106 (Dropout)	(None, 24, 48)	0
lstm_38 (LSTM)	(None, 48)	18,624
dropout_107 (Dropout)	(None, 48)	0
dense_63 (Dense)	(None, 1)	49

Total params: 29,425 (114.94 KB)
Trainable params: 29,425 (114.94 KB)
Non-trainable params: 0 (0.00 B)

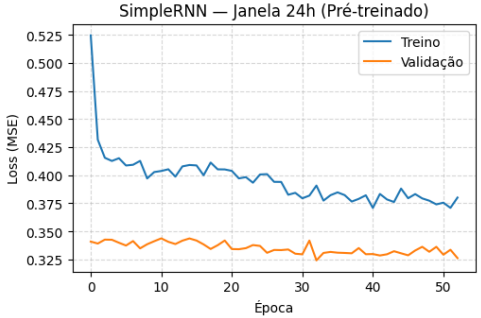
GRU

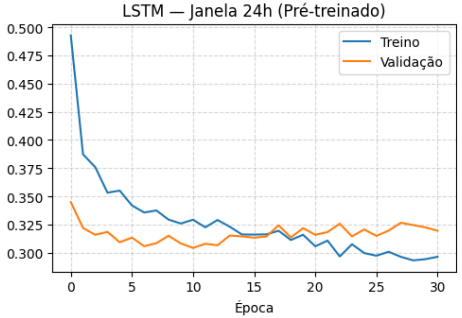
Treinando modelo GRU com janela 24...
Model: "sequential_64"

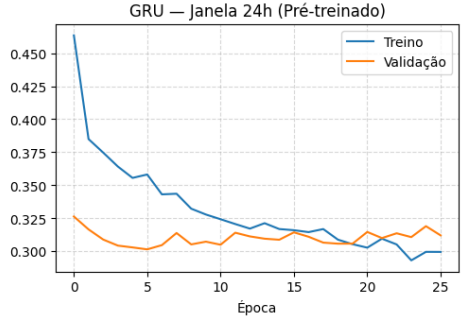
Layer (type)	Output Shape	Param #
gru_32 (GRU)	(None, 24, 48)	8,208
dropout_108 (Dropout)	(None, 24, 48)	0
gru_33 (GRU)	(None, 48)	14,112
dropout_109 (Dropout)	(None, 48)	0
dense_64 (Dense)	(None, 1)	49

Total params: 22,369 (87.38 KB)
Trainable params: 22,369 (87.38 KB)
Non-trainable params: 0 (0.00 B)

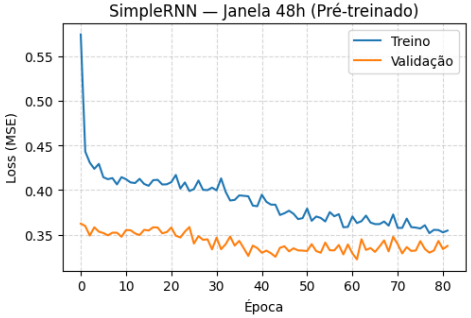
Janela **24h**

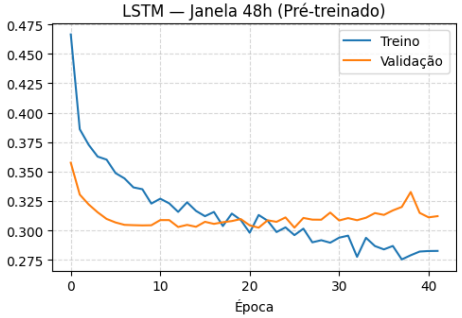


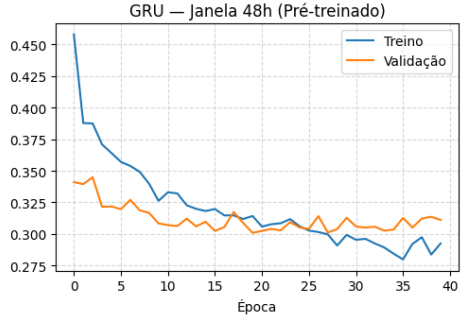




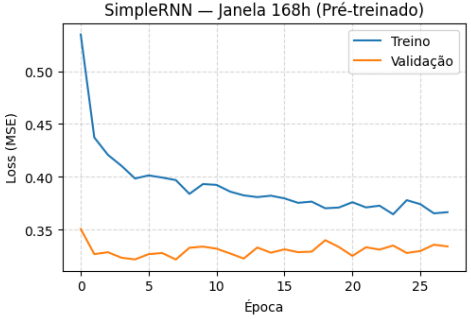
Janela **48h**

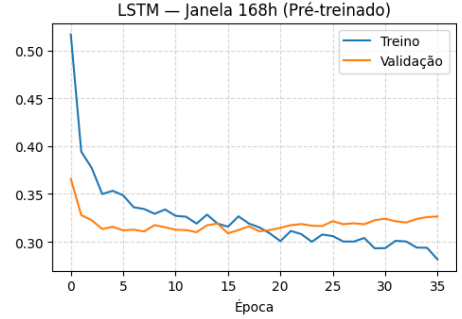


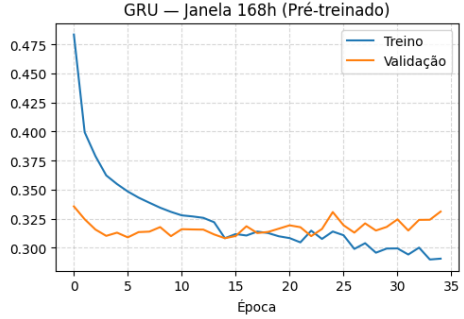




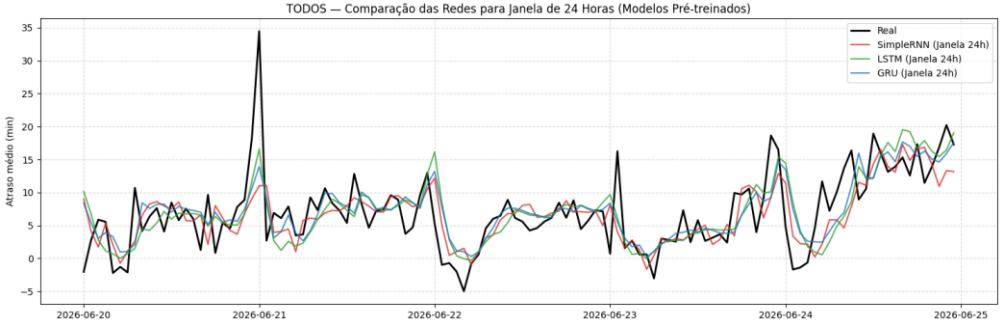
Janela **168h**



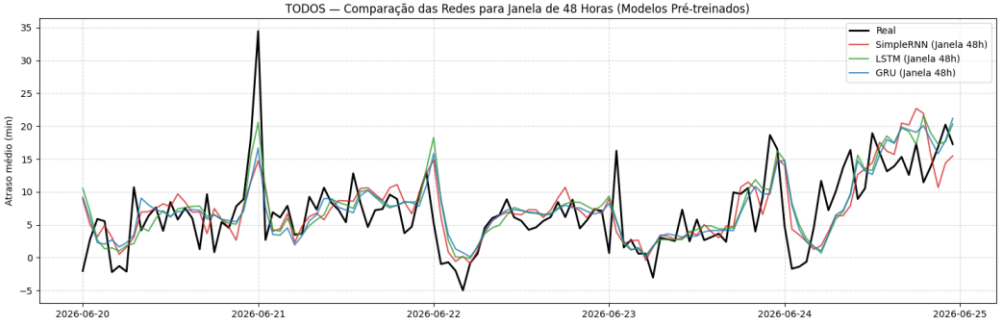




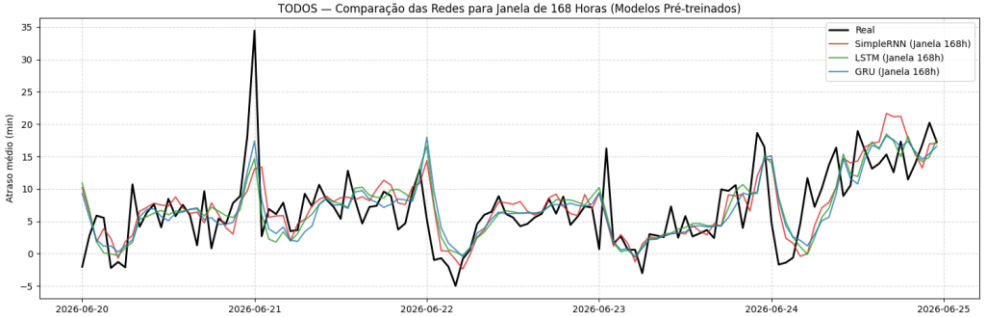
Janela **24h**



Janela **48h**



Janela **168h**



Busca de hiperparâmetros com Optuna

Hiperparâmetro	Espaço de busca
Arquitetura	SimpleRNN, LSTM, GRU
Unidades	16 a 64 (passo 16)
Dropout	0,0 a 0,5
Taxa de aprendizado	10^{-4} a 10^{-2}
Batch size	16, 32, 64

Otimização bayesiana (TPE) · 5 tentativas de até 15 épocas · métrica: perda (MSE) na validação · janela de 24 h

Melhor configuração

GRU

16 unidades

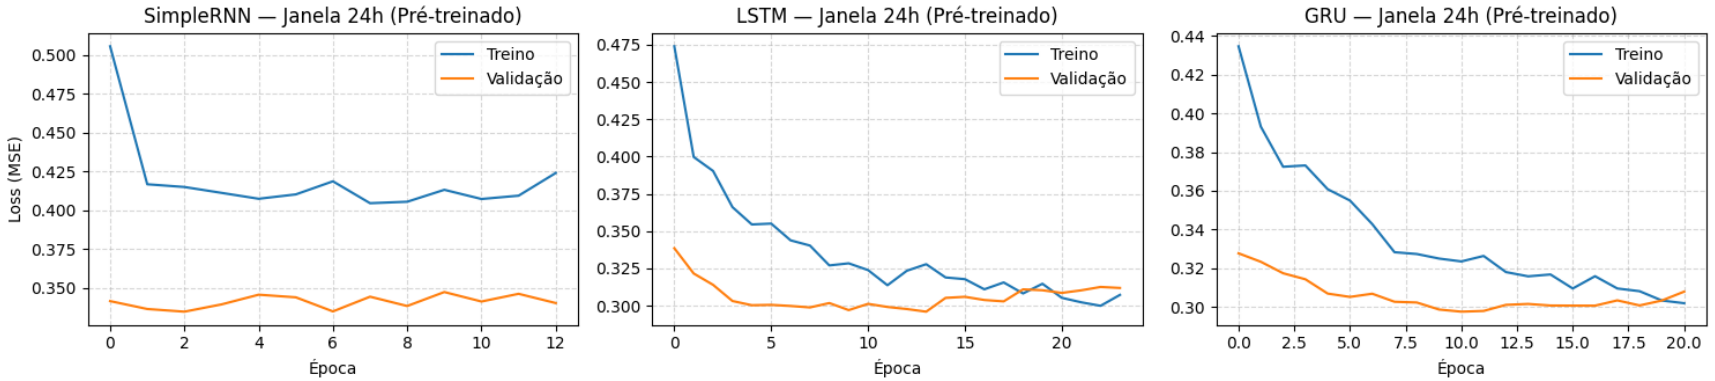
dropout 0,4

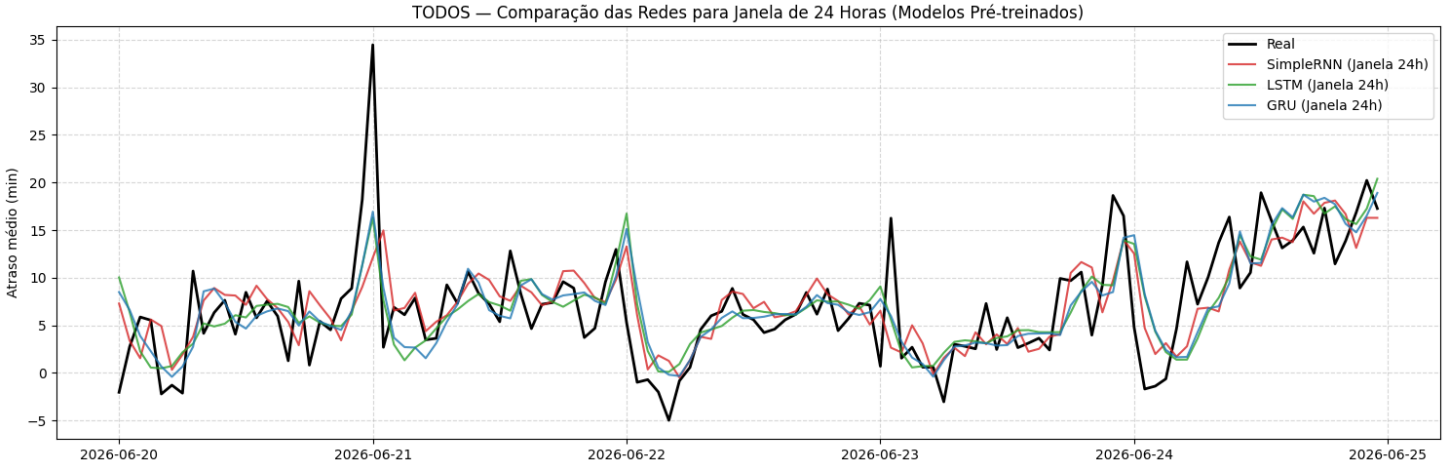
lr ≈ 0.00351

batch 16

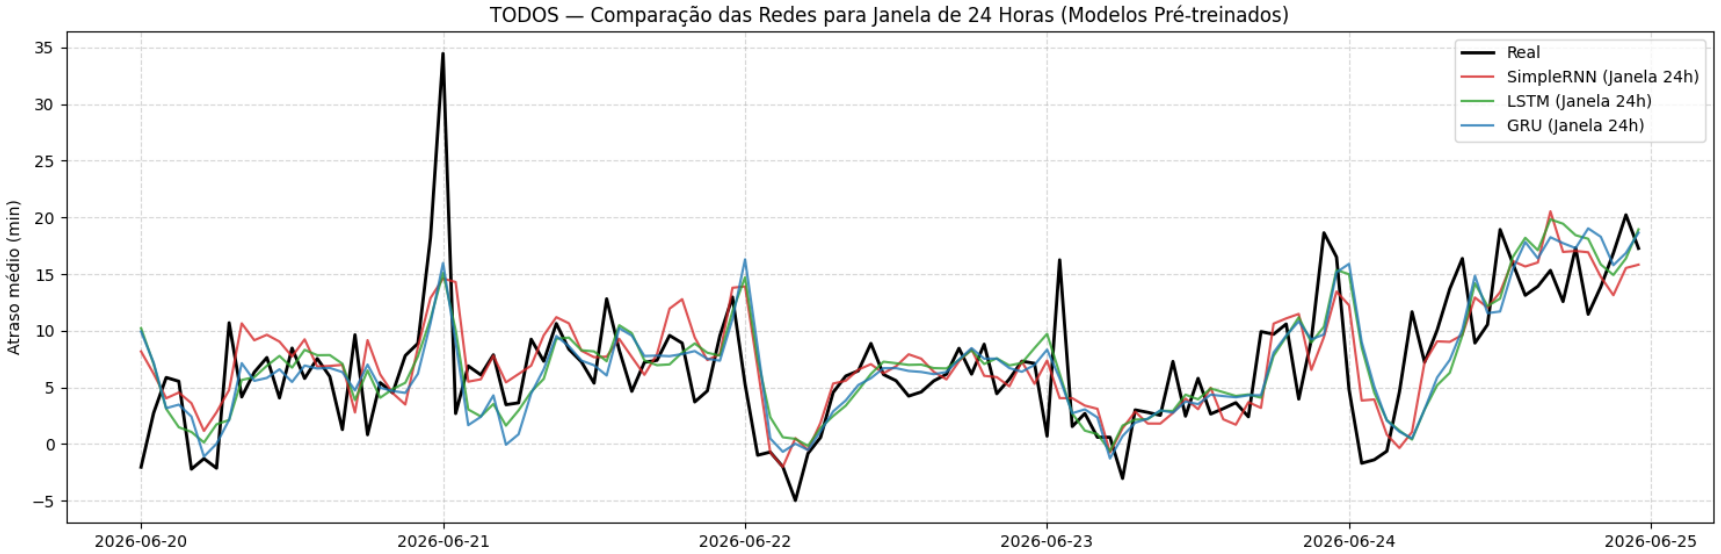
Perda de validação: 0,2990

Gráficos e Resultados com Otimização de Hiperparâmetros com Optuna





As redes seguem o ciclo diário, não os picos



Padrão capturado
As três redes seguem a subida e a descida diárias e a persistência entre horas vizinhas

Limitação
Picos isolados, como o de 21/06, são subestimados: a causa (clima, falhas) não está nas entradas

Conclusões e próximos passos

Conclusões

- LSTM e GRU reduzem o erro frente à SimpleRNN em todas as janelas
- A GRU otimizada atingiu o menor MAE (3,05 min) com menor número de parâmetros que a LSTM
- A janela de 24h otimizada é ideal para tempo real
- Custo exigiu uso de GPU

Próximos passos

- Incluir meteorologia, feriados e dados por aeroporto
- Ampliar a busca do Optuna

https://colab.research.google.com/drive/1u-z8gK_VC2RV0e9M5NF4Jy3HnG1J9xVB?usp=sharing