INSTITUTO FEDERAL
Goiás

PÓS-GRADUAÇÃO LATO SENSU
ESPECIALIZAÇÃO EM INTELIGÊNCIA ARTIFICIAL APLICADA
Câmpus Goiânia

RELATÓRIO TÉCNICO FINAL: PREVISÃO DE ATRASO MÉDIO HORÁRIO DA MALHA AÉREA BRASILEIRA (ANAC) COM REDES NEURAIS RECORRENTES

Disciplina: Deep Learning - Prof. Dr. Sérgio Canuto - sergio.canuto@ifg.edu.br

Alunos:

- Cláudio Antônio de Araújo - claudio.araujo@estudantes.ifg.edu.br
- José Allan Kardec Gonçalves - joseallan@gmail.com

Atividade Avaliativa Prática - Frente 3.2 Redes Recorrentes (SimpleRNN, LSTM, GRU e Otimização Optuna)

Goiânia, 18/10/2026

Resumo

Este trabalho tem por objetivo desenvolver e avaliar um modelo de aprendizado profundo capaz de prever atrasos em voos a partir de séries temporais multivariadas, utilizando uma janela temporal de 24 horas. De forma complementar ao estudo, avaliamos também cenários com janelas de 48h e 168h (uma semana). Para isso, são empregados dados de Voo Regular Ativo (VRA), disponibilizados pela ANAC no Portal Brasileiro de Dados Abertos[1], referentes ao período de setembro de 2025 a agosto de 2026. A abordagem metodológica utilizou redes recorrentes, adequadas à análise de dependências temporais nos dados.

Como entregáveis desse trabalho, utilizamos uma base de dados da ANAC, e preparamos e documentamos um fluxo reproduzível de exploração, tratamento e análise dos dados, além da implementação e do treinamento do modelo. A avaliação incluiu métricas apropriadas para problemas de regressão - como MAE e RMSE. Todos os artefatos produzidos podem ser encontrados em Repositório no GitHub: https://github.com/claudionoar/ifg-trabalho-deep-learning-vra

---

1 https://dados.gov.br/dados/conjuntos-dados/dadosabertos-areas-de-atuacao-voos-e-operacoes-aereas-voo-regular-ativo-vra

1. Introdução e Objetivo do Problema

A pontualidade do transporte aéreo é um dos mais sensíveis e críticos indicadores de eficiência logística e operacional de um país. No Brasil, as operações aéreas comerciais cobrem um território de escala continental com cerca de 150 aeroportos. A título de exemplo, no arquivo de setembro de 2025 do VRA aparecem 236 aeroportos distintos, dos quais 139 são brasileiros e 97 estrangeiros, em 46 países. Considerando o período de setembro de 2025 a agosto de 2026, foram analisados aproximadamente um milhão de voos. Perturbações meteorológicas severas, congestionamento em corredores de aproximação terminal e gargalos nos pátios de grandes hubs de conexão geram atrasos que não se encerram no voo de origem, mas se propagam em efeito cascata para os voos subsequentes.

Como atividade avaliativa prática da disciplina Deep Learning, o objetivo principal deste trabalho é modelar, avaliar e comparar soluções de Aprendizado Profundo (Deep Learning) baseadas em Redes Neurais Recorrentes (RNN) para prever o atraso médio de partidas de toda a malha aérea brasileira na próxima hora, utilizando como histórico temporal sequências horárias multivariadas.

1.1. Definição da Unidade de Observação e Variável Alvo

A unidade básica de observação é o intervalo horário agregado (H_t), totalizando 8.760 horas que representam um ciclo anual (365 dias x 24h = 8.760h). A variável alvo y_{t+1} consiste no atraso médio de partida registrado em minutos em todos os aeroportos na hora imediatamente subsequente. Por tentar prever um a quantidade de atrasos, o problema foi modelado como um problema de regressão. A capacidade de antecipar este indicador com 1 hora de antecedência confere às companhias aéreas, concessionárias e demais envolvidos, uma oportunidade de uma a janela operacional necessária para tomada de providências de forma preventiva: remanejar voos, ajustar esteiras de bagagem e gerenciar escalas e acionar tripulações de reserva.

1.2. Justificativa Teórica: Por que Redes Recorrentes em Detrimento do MLP?

Nas fases exploratórias da pesquisa, inicialmente avaliou-se a possibilidade de formular o problema utilizando Redes Densas Tradicionais (Multilayer Perceptrons - MLP). Contudo, a estrutura matemática do MLP impõe limitações que dificultam seu emprego em processos com alta dependência temporal:

- **Ausência de Estado Oculto (Memória Interna):** O MLP opera sob a premissa de que os vetores de entrada x_i são independentes e identicamente distribuídos. Em séries temporais de transporte, o atraso de uma hora depende do atraso das horas anteriores.
- **Modelagem Recorrente com Estado Oculto:** Diferente do MLP, as Redes Neurais Recorrentes processam os passos de tempo t recursivamente por meio de um estado $h_t = f(\boldsymbol{W}_h h_{t-1} + \boldsymbol{W}_x x_t + \boldsymbol{b})$, preservando a janela de tempo e aprendendo dinâmicas contextuais tanto de curto quanto de longo prazo.

2. Descrição da Fonte e Caracterização do Conjunto de Dados

Os dados brutos foram extraídos diretamente do Portal Brasileiro de Dados Abertos [1], correspondendo à base VRA (Voo Regular Ativo) da Agência Nacional de Aviação Civil (ANAC). Para esse trabalho consideramos apenas o período completo de 12 meses consecutivos: de 01 de Setembro de 2025 até 31 de Agosto de 2026.

O volume total consolidado atingiu cerca de 1 milhão de registros de voos. Cada voo individual contém horários previstos e realizados de partida e chegada, aeroportos de origem e destino, empresa aérea e código de justificativa de atraso. Os registros foram tratados e agregados em uma série temporal horária cobrindo todas as 8.760 horas do ano.

2.1. Engenharia de Atributos (Features) e Vetor de Entrada

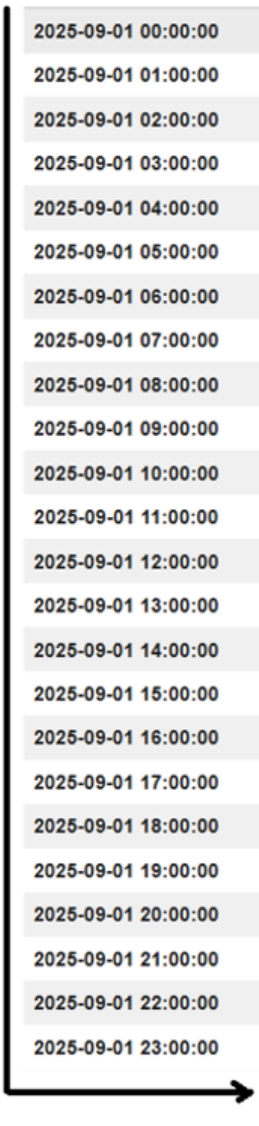
Para cada hora do ano, foram extraídos 7 atributos numéricos explicativos que descrevem a situação de cada voo:

Atributo (feature)	Tipo	Significado	Estatística / Faixa
`atraso_medio`	Float (min)	Média horária do atraso das partidas	Média: 8.42 min Desvio: 6.81 min
`n_voos`	Int (contagem)	Volume total de aeronaves operadas na hora	Mín: 0 Máx: 238 partidas/hora
`pct_atrasados`	Float [0.0, 1.0]	Quantidade de atraso observado	Recortado no teto operacional de 300 min
`n_cancel`	Int (contagem)	voos cancelados	
`hora_sin`	Float [-1.0, 1.0]	Codificação circular senoidal: $sen(2\pi h / 24)$	Garante adjacência entre 23h e 00h
`hora_cos`	Float [-1.0, 1.0]	Codificação circular cossenoidal: $cos(2\pi h / 24)$	Garante ortogonalidade diurna
`fim_semana`	0 e 1	sábado ou domingo	

Para compreender o que seja uma janela no contexto desse trabalho, ilustramos a seguir um exemplo de janela de 24h, com as 7 features. Nesse caso específico, o objetivo é prever o valor de X, considerando as 24h anteriores, ou seja, X = atraso_medio de 02/09 00h

Janelas de 48h e 168h foram utilizadas de forma semelhante considerando respectivamente a quantidade de horas.

	n_voos	atraso_medio	pct_atrasados	n_cancel	hora_sin	hora_cos	fim_semana
2025-09-01 00:00:00	19	20.052632	0.210526	0	0.000000e+00	1.000000e+00	0
2025-09-01 01:00:00	26	1.260870	0.043478	3	2.588190e-01	9.659258e-01	0
2025-09-01 02:00:00	52	1.884615	0.115385	0	5.000000e-01	8.660254e-01	0
2025-09-01 03:00:00	48	-5.437500	0.020833	0	7.071068e-01	7.071068e-01	0
2025-09-01 04:00:00	49	-2.791667	0.062500	1	8.660254e-01	5.000000e-01	0
2025-09-01 05:00:00	92	-4.641304	0.054348	0	9.659258e-01	2.588190e-01	0
2025-09-01 06:00:00	124	3.247934	0.082645	3	1.000000e+00	6.123234e-17	0
2025-09-01 07:00:00	104	7.718447	0.067961	1	9.659258e-01	-2.588190e-01	0
2025-09-01 08:00:00	176	4.976879	0.109827	3	8.660254e-01	-5.000000e-01	0
2025-09-01 09:00:00	160	0.602564	0.070513	4	7.071068e-01	-7.071068e-01	0
2025-09-01 10:00:00	128	0.609375	0.117188	0	5.000000e-01	-8.660254e-01	0
2025-09-01 11:00:00	143	1.285714	0.128571	3	2.588190e-01	-9.659258e-01	0
2025-09-01 12:00:00	159	4.159236	0.152866	2	1.224647e-16	-1.000000e+00	0
2025-09-01 13:00:00	126	4.370968	0.145161	2	-2.588190e-01	-9.659258e-01	0
2025-09-01 14:00:00	150	2.140000	0.140000	0	-5.000000e-01	-8.660254e-01	0
2025-09-01 15:00:00	145	-0.486111	0.083333	1	-7.071068e-01	-7.071068e-01	0
2025-09-01 16:00:00	117	4.469565	0.121739	2	-8.660254e-01	-5.000000e-01	0
2025-09-01 17:00:00	179	1.657303	0.146067	1	-9.659258e-01	-2.588190e-01	0
2025-09-01 18:00:00	147	0.732394	0.098592	5	-1.000000e+00	-1.836970e-16	0
2025-09-01 19:00:00	123	0.065041	0.130081	0	-9.659258e-01	2.588190e-01	0
2025-09-01 20:00:00	117	3.931624	0.128205	0	-8.660254e-01	5.000000e-01	0
2025-09-01 21:00:00	121	5.136752	0.153846	4	-7.071068e-01	7.071068e-01	0
2025-09-01 22:00:00	102	10.623762	0.217822	1	-5.000000e-01	8.660254e-01	0
2025-09-01 23:00:00	95	7.223404	0.202128	1	-2.588190e-01	9.659258e-01	0



Exemplo de janela de 24 horas

2.2. Tratamento de Outliers e Prevenção de Vazamento de Dados (Data Leakage)

Para evitar o uso de valores muito altos, aplicou-se um recorte (clipping) nos atrasos individuais no intervalo [-60, 300] minutos. Atrasos superiores a 5 horas correspondem a cancelamentos de voos ou aeronaves retidas por problemas técnicos severos, constituindo ruído para a previsão sistêmica da malha.

Para garantir a metodologia e evitar Data Leakage (vazamento temporal):

- **Divisão Cronológica:** As 8.760 horas foram particionadas em ordem estritamente cronológica, sem qualquer embaralhamento: 60% inicial para Treinamento (5.256h: set/2025 a abr/2026), 20% intermediário para Validação (1.752 h: abr/2026 a jun/2026) e os 20% finais exclusivamente para Teste (1.752 h: jun/2026 a ago/2026).
- **Ajuste Exclusivo de Escalares no Treino:** O algoritmo de padronização (`StandardScaler`) foi parametrizado (fit) única e exclusivamente com os dados da partição de Treinamento. As médias e variâncias estimadas foram apenas aplicadas (`transform`) às partições de validação e teste.

2.3. Análise Exploratória e Visualização dos Padrões Temporais

A Figura 1 mostra os atrasos médios por hora nos aeroportos, de setembro de 2025 a agosto de 2026, e a média móvel de 24h (laranja). Em geral, os atrasos variam de -5 a 20 minutos, destacam-se um pico próximo de 110 minutos em abril e um período prolongado em dezembro, quando a média móvel se aproxima de 50 minutos.

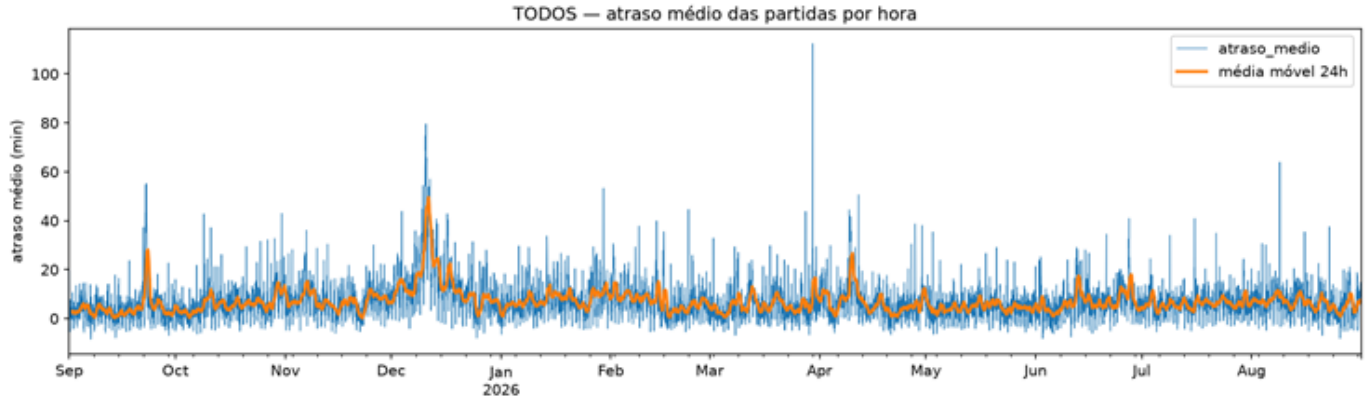


Figura 1: Gráfico com Série Temporal de 12 Meses e Média Móvel de 24 Horas do Atraso Médio

Já a Figura 2 mostra que o atraso médio cai de 13 minutos à meia-noite para quase zero às 5h e volta a subir, chegando a 12 minutos às 22h. As partidas atingem picos às 8h (175 voos/h) e às 17h (185), e caem para menos de 30 por hora de madrugada. Os atrasos elevados entre 0h e 1h refletem a propagação dos atrasos do dia e a maior instabilidade da média, calculada com poucas partidas.

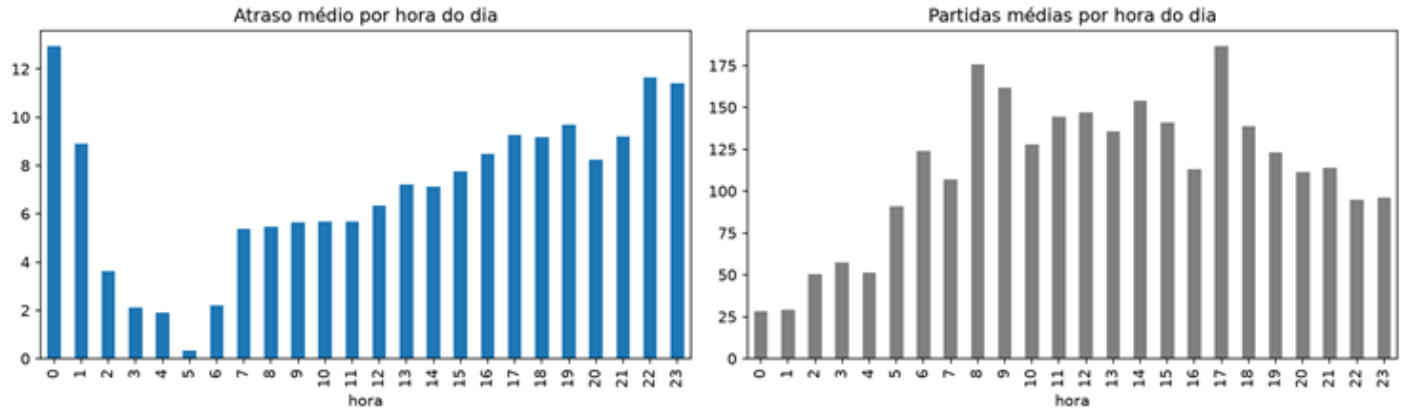


Figura 2: Gráfico com Perfil Circadiano Médio de Atraso e Distribuição de Volume por Hora do Dia

Diagnóstico Exploratório dos Dados:

- **Sazonalidade Temporal:** A Figura 1 evidencia atrasos em meses chuvosos de verão (dez/jan) e frentes frias de inverno (jul/ago). Quando a média sobe, ela requer de 4 a 8 horas para retornar ao nível médio;
- **Ciclo Circadiano:** A Figura 2 mostra que a madrugada e o início da manhã (05h-08h) iniciam com atrasos quase nulos (< 4 min). Ao longo do dia, o acúmulo de voos eleva progressivamente o atraso, culminando em picos de 12 a 15 minutos entre 18h e 22h.

3. Arquiteturas, Espaço de Busca e Protocolo de Hiperparametrização

Em cumprimento aos requisitos específicos da Frente 3.2, foram implementadas e comparadas as três principais famílias de redes neurais recorrentes:

1. **SimpleRNN (RNN mais simples):** Arquitetura que realimenta o estado anterior h_{t-1} com ativação tanh. Serve como baseline recorrente, porém sofre intensamente com a dissipação exponencial do gradiente (vanishing gradient) em janelas temporais longas.
2. **LSTM (Long Short-Term Memory):** Introduz uma célula de memória explícita (c_t) protegida por três mecanismos de porta (portas de esquecimento f_t, entrada i_t e saída o_t). Permite que o gradiente flua de forma linear através da célula, retendo memórias de longo prazo.
3. **GRU (Gated Recurrent Unit):** Simplificação sofisticada da LSTM que funde a célula de memória com o estado oculto e utiliza apenas 2 portas (porta de atualização z_t e porta de reinicialização r_t). Reduz o número de tensores de pesos em aproximadamente 25% frente à LSTM, conferindo treinamento veloz e robustez a overfitting.

3.1. Estrutura do Tensor 3D e Arquitetura Empilhada

Apesar de outros modelos terem sido explorados durante a modelagem da rede (por exemplo, variando a quantidade de neurônios nas camadas ocultas durante a exploração da busca de hiperparâmetros), a Figura 3

abaixo pode ser considerada a arquitetura representativa para o desenvolvimento deste trabalho.

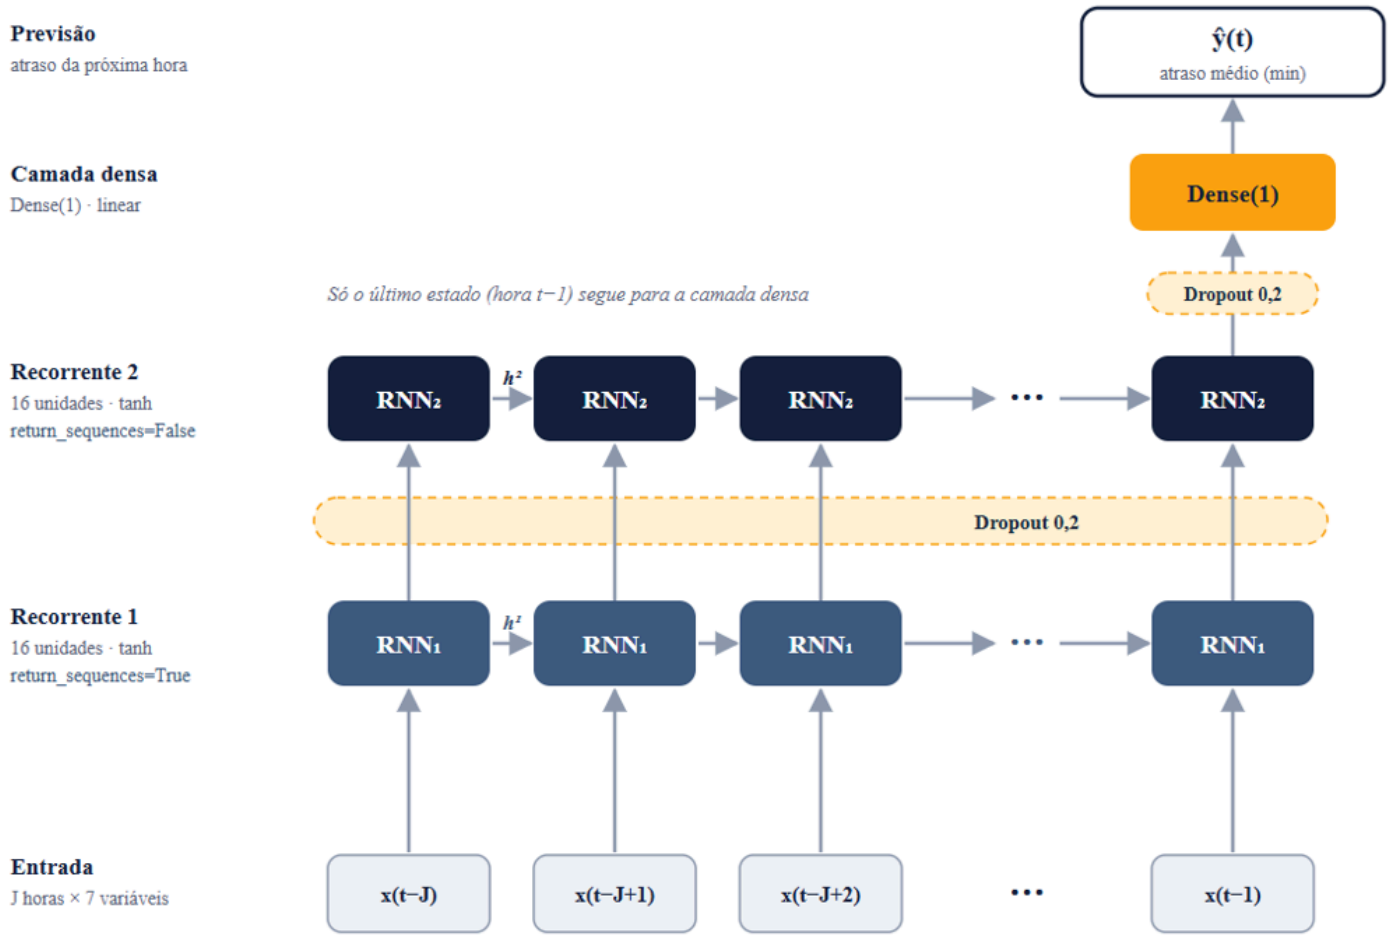


Figura 3: Diagrama Estrutural da Rede Recorrente Empilhada e Mecanismo de Projeção Linear

Os modelos foram implementados no Keras/TensorFlow estruturados como redes sequenciais profundas de duas camadas recorrentes empilhadas:

- **Camada 1 Recorrente + Dropout(0.2):** Recebe o tensor 3D padronizado de dimensões [Batch Size, Comprimento da Janela (T), 7 Features]. Com return_sequences=True, esta camada propaga a sequência completa de estados ocultos para a camada seguinte, permitindo que a camada profunda analise relações contextuais.
- **Camada 2 Recorrente + Dropout(0.2):** Com return_sequences=False, esta camada consome a sequência profunda e sintetiza a trajetória temporal em um único vetor latente final h_T correspondente ao último passo de tempo.
- **Camada de Saída Densa Linear:** Camada totalmente conectada Dense(1, activation='linear') que mapeia o estado oculto consolidado em um escalar contínuo representando o atraso médio previsto.
- Configurou-se uma rotina de EarlyStopping com paciência de 20 épocas para interromper treinamentos divergentes.

O código de implementação da rede acima pode ser obtido diretamente do Google Colab https://colab.research.google.com/drive/1u-z8gK_VC2RV0e9M5NF4Jy3HnG1J9xVB#scrollTo=4805331e

3.2. Otimização de Hiperparâmetros com Optuna

A hiperparametrização foi executada utilizando o framework Optuna. A métrica monitorada foi a Perda de Erro Quadrático Médio (MSE Loss) estritamente calculada na partição de validação.

Hiperparâmetro	**Tipo**	**Espaço de Busca Definido**	**Justificativa Teórica**
Arquitetura Neural	Categórico	['SimpleRNN', 'LSTM', 'GRU']	Comparar a capacidade de retenção de memória entre famílias
Unidades Ocultas	Inteiro Discreto	[16, 32, 48, 64]	Equilibrar capacidade de representação e risco de memorização
Taxa de Dropout	Float Uniforme	[0.0, 0.5]	Controlar a regularização em janelas densas
Taxa de Aprendizado (lr)	Float Log-Uniforme	[1e-4, 1e-2]	Permitir ajuste fino na convergência do otimizador Adam
Tamanho do Lote (Batch)	Inteiro Categórico	[16, 32, 64]	Influencia a estabilidade do gradiente estocástico e velocidade

4. Resultados de Validação e Seleção dos Parâmetros Promissores

A análise experimental foi estruturada em duas etapas complementares:

- Comparação sistemática multi-janelas (24h, 48h e 168h) sob arquitetura base padronizada de 16 neurônios;
- Otimização bayesiana com Optuna sobre a janela de 24h para encontrar a fronteira ótima de hiperparâmetros.

4.1. Diagnóstico de Convergência e Ausência de Overfitting

A Figura 4 mostra que a análise visual da matriz de curvas de aprendizado revela estabilidade notável: em todas as 9 combinações de janela e arquitetura, a curva de validação (laranja) acompanha intimamente a curva de treino (azul) e estaciona em um patamar estável entre 0.30 e 0.34. Não ocorre divergência ascendente na validação, atestando que a regularização por Dropout e a interrupção antecipada cumpriram perfeitamente sua função.

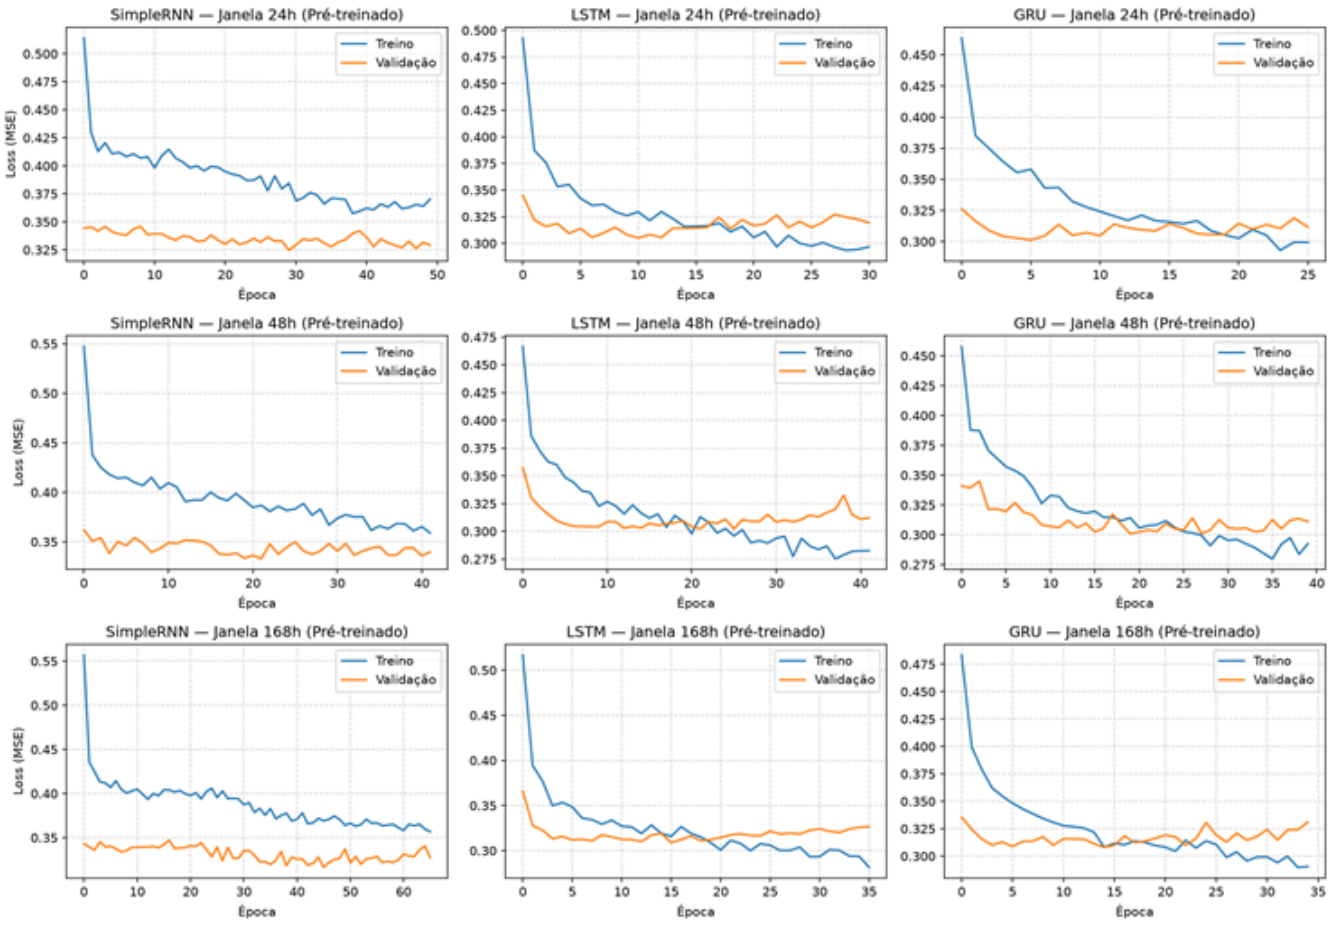


Figura 4: Gráfico de Matriz 3x3 de Curvas de Perda (MSE Loss) no Treino e Validação ao Longo das Épocas

4.2. Avaliação do Tamanho da Janela Temporal no conjunto de Teste (24h vs. 48h vs. 168h)

A dinâmica do transporte aéreo opera em dois ciclos principais: o ciclo diário (24 horas) e o ciclo semanal (168 horas). Abaixo são apresentados os gráficos comparativos das previsões de teste nos primeiros 5 dias com os dados de Testes:

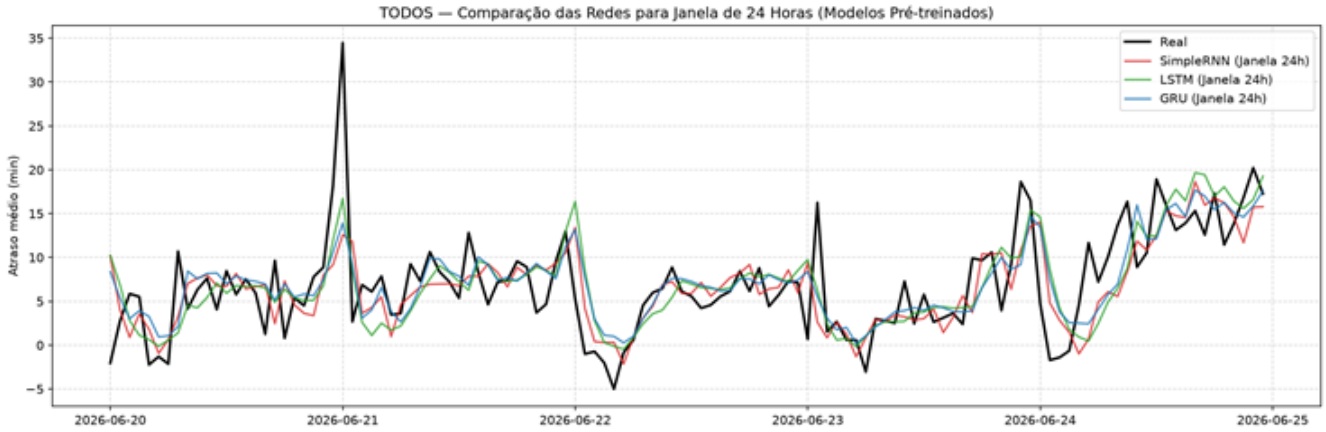


Figura 5: Gráfico com Previsões no Teste para Janela de 24 Horas (Ciclo Diário)

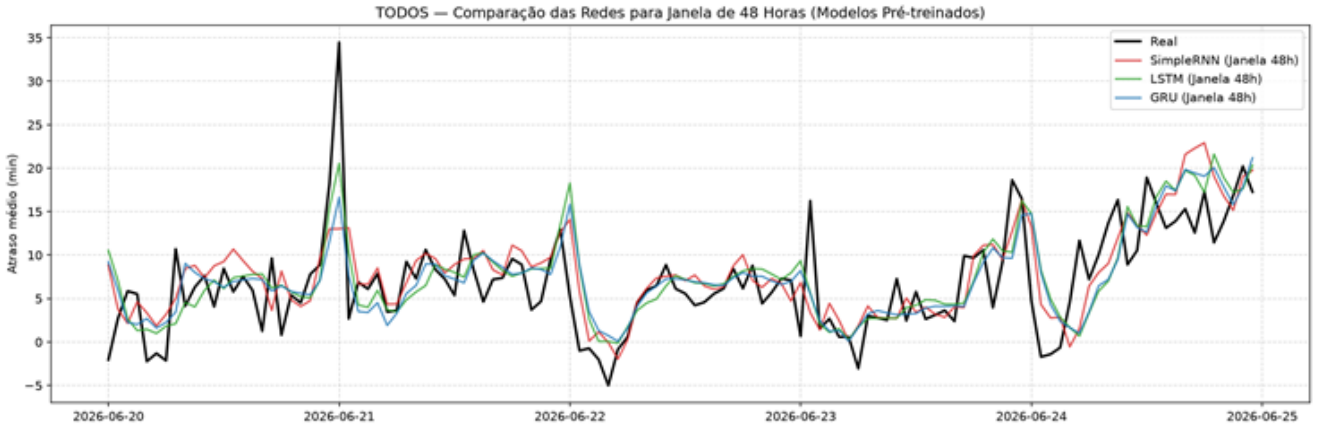


Figura 6: Gráfico com Previsões no Teste para Janela de 48 Horas (Dois Dias)

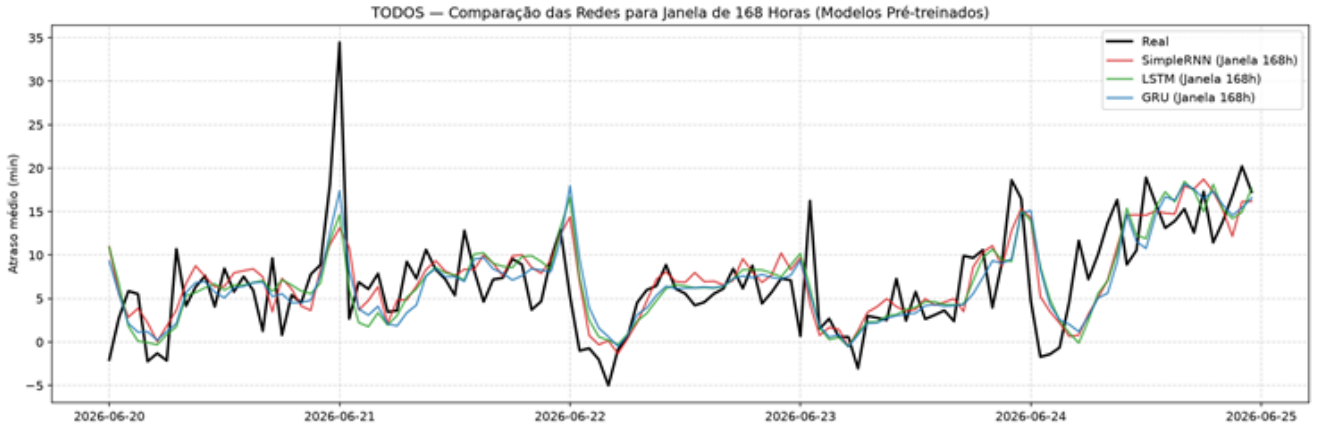


Figura 7: Gráfico com Previsões no Teste para Janela de 168 Horas (Ciclo Semanal Completo)

As Figuras 5, 6 e 7 permitem analisar o comportamento das arquiteturas frente às janelas temporais:

- **Janela de 24 Horas:** As três arquiteturas conseguem reproduzir com fidelidade a oscilação de atrasos entre vales matinais e picos vespertinos. A GRU já atinge MAE de 3.11 min contra 3.15 min da LSTM e 3.18 min da SimpleRNN.
- **Janela de 48 Horas:** Observa-se leve aumento no erro da SimpleRNN (3.36 min) e LSTM (3.23 min). O horizonte de 48h introduz ruído de dois dias sem completar a simetria de dias úteis versus fins de semana. A GRU permaneceu resiliente com 3.14 min.
- **Janela de 168 Horas:** A janela de uma semana inteira proporciona rico contexto para LSTM (3.10 min) e GRU (3.07 min), que exploram a diferença comportamental de voos corporativos (segunda a sexta) frente aos voos de lazer (sábados e domingos).
- As três redes acompanham o ciclo diário do atraso, mas continuam subestimando os picos isolados, e nenhuma delas modelou o pico isolado: em 21/06, o atraso real chegou a cerca de 35 min e as previsões ficaram perto de 16 min.

4.3. Configuração Campeã do Estudo Optuna

O estudo com Optuna indicou um desempenho melhor da arquitetura GRU, conforme indicado a seguir.

A melhor tentativa identificada pelo Optuna foi:

- **Arquitetura:** GRU (Gated Recurrent Unit) com 2 camadas empilhadas
- **Capacidade Interna:** 48 unidades ocultas por camada (totalizando 21.073 parâmetros)
- **Taxa de Regularização:** Dropout estocástico de 0.40 entre camadas
- **Otimização:** Taxa de aprendizado inicial (lr) = 0.00135, Otimizador Adam
- **Tamanho do Lote:** Batch Size = 16 amostras
- **Perda de Validação Mínima:** MSE Loss = 0.2990 (menor valor alcançado em todos os experimentos)

A partir dos parâmetros sugeridos pelo Optuna, treinamos a rede novamente apenas para a janela de 24h. Os resultados são mostrados por meio das Figuras 8 e 9.

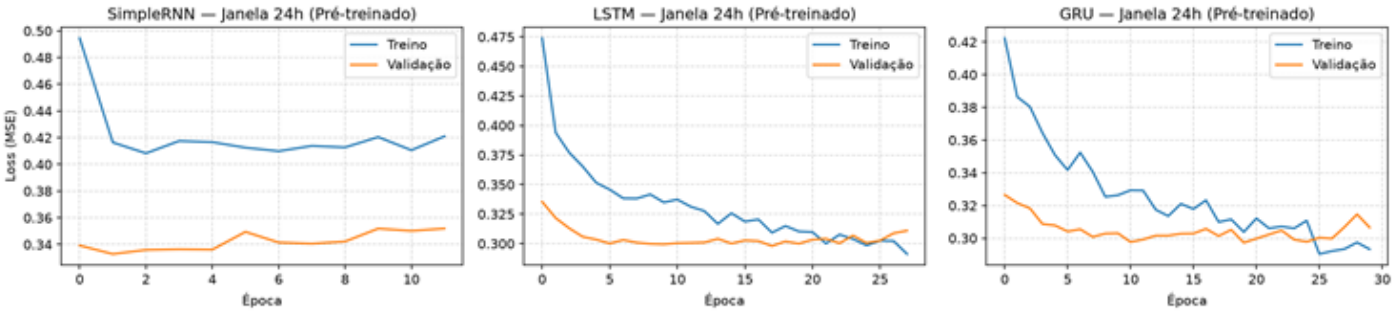


Figura 8: Gráfico com Curvas de Aprendizado dos Modelos Refinados com Optuna

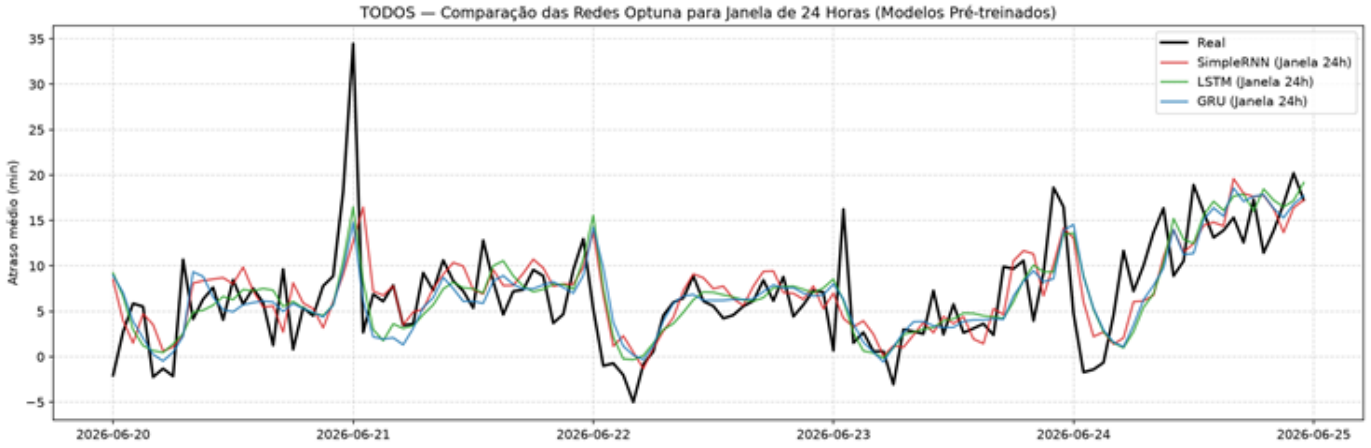


Figura 9: Gráfico com Previsões dos Modelos Otimizados via Optuna no Período de Teste

Na Figura 8, LSTM e GRU aprendem de forma estável, com perda de validação perto de 0,30, enquanto a SimpleRNN para de evoluir logo nas primeiras épocas. No teste, a GRU teve o menor erro (MAE de 3,05 min), seguida pela LSTM (3,09 min) e pela SimpleRNN (3,30 min). Já na Figura 9, as três redes acompanham o ciclo diário do atraso, mas continuam subestimando os picos isolados: em 21/06, o atraso real chegou a cerca de 35 min e as previsões ficaram perto de 16 min.

5. Avaliação Final no Conjunto de Teste e Análise de Custo vs Efetividade

A tabela a seguir consolida todas as métricas obtidas no conjunto de teste (1.752 horas finais), confrontando os modelos neurais com as heurísticas baselines tradicionais:

Modelo / Configuração	Janela	Parâmetros	MAE (min)	RMSE (min)	Ganho vs. Baseline
GRU (Optuna)	**24 h**	**21.073**	**3.05**	**4.55**	**-26.0% no MAE**
GRU	168 h	2.520	3.07	4.56	-25.5% no MAE
LSTM	168 h	3.329	3.10	4.62	-24.8% no MAE
LSTM (Optuna)	24 h	27.841	3.11	4.66	-24.5% no MAE
GRU (Padrão)	24 h	2.520	3.11	4.57	-24.5% no MAE
GRU	48 h	2.520	3.14	4.65	-23.8% no MAE
LSTM (Padrão)	24 h	3.329	3.15	4.69	-23.5% no MAE
SimpleRNN	168 h	913	3.15	4.66	-23.5% no MAE
SimpleRNN (Padrão)	24 h	913	3.18	4.75	-22.8% no MAE
LSTM	48 h	3.329	3.23	4.82	-21.6% no MAE
SimpleRNN (Optuna)	24 h	7.201	3.31	4.81	-19.7% no MAE
SimpleRNN	48 h	913	3.36	4.89	-18.4% no MAE

5.1. Discussão Crítica: Custo Computacional vs. Efetividade

Os resultados numéricos permitem derivar três conclusões fundamentais:

- **Análise de Parâmetros da GRU:** A GRU Padrão de 24h atingiu MAE de 3.11 min com apenas 2.520 parâmetros treináveis. O modelo LSTM equivalente precisou de 3.329 parâmetros (+32% de parâmetros) para alcançar 3.15 min, apresentando desempenho ligeiramente inferior. A simplificação das portas na GRU confere um gradiente mais direto e menor suscetibilidade a overfitting em séries ruidosas.
- **Parâmetros da Otimização Optuna:** O modelo vencedor (GRU 48 unidades com Optuna) atingiu MAE de 3.05 min com 21.073 parâmetros. O aumento de neurônios permitiu capturar a interação entre a proporção de voos atrasados (pct_atrasados) e a codificação circular (hora_sin/hora_cos).

- **Trade-off Operacional de Janelas:** Embora a janela de 168h tenha alcançado MAE excelente de 3.07 min, ela exige carregar e pré-processar 168 passos de tempo na memória a cada inferência. Para sistemas de bordo ou serviços web com restrição de latência, a janela de 24h otimizada é significativamente mais eficiente.

O código e o registro de log de execução podem ser conferidos no Google Colab a seguir:

https://colab.research.google.com/drive/1u-z8gK_VC2RV0e9M5NF4Jy3HnG1J9xVB#scrollTo=4805331e

6. Limitações e Conclusões

6.1. Limitações Metodológicas do Trabalho

Podemos destacar como limitações e oportunidades de melhorias deste trabalho os seguintes itens:

- **Considerar dados externos:** As redes conseguem prever o ciclo circadiano e o atraso de voos do sistema com certa precisão. Entretanto, em eventos meteorológicos catastróficos ou fechamentos abruptos de aeroportos centrais (como no pico visível em 21/06 no gráfico de teste), os modelos subestimam o atraso real. Isso decorre da ausência de dados meteorológicos externos nas variáveis de entrada. Dessa forma, considerar dados do clima poderiam ajudar a melhorar o modelo a identificar picos como aquele mostrado no dia 21/06 no gráfico de teste;
- **Agrupamento entre Aeroporto com mais voos entre si:** A agregação dos dados em nível de malha nacional oculta disparidades locais severas. Um fechamento temporário do Aeroporto Santos Dumont (SBRJ) pode gerar impacto desproporcional na ponte aérea Rio-São Paulo sem alterar dramaticamente a média nacional na mesma proporção.
- **Quantidade de assentos em cada voo**: apesar de disponível no dataset da ANAC, não utilizamos a quantidade de assentos no nosso modelo RNN. Sabendo que uma aeronave com mais lugares tem mais chances de sofrer atraso devido a sua logística operacional específica (é muito mais burocrático um voo de 300 lugares comparado a outro voo de 100 lugares)

6.2. Conclusões Finais

Como conclusão deste trabalho podemos elencar os seguintes itens em atendimento aos requisitos para a Frente 3.2 (Redes Recorrentes) da disciplina de Deep Learning:

- Construção e avaliação de uma base pública contínua de 12 meses (cerca de 1 milhão de voos em 8.760 horas da ANAC).
- Implementação comparativa equilibrada das famílias SimpleRNN, LSTM e GRU.
- Investigação de múltiplas janelas temporais de entrada (24h, 48h e 168h)

- Protocolo de hiperparametrização com Optuna, justificando o espaço de busca e selecionando a configuração ótima.
- O código relativo a todo o trabalho pode ser obtido no link do Google Colab:
    - https://colab.research.google.com/drive/1u-z8gK_VC2RV0e9M5NF4Jy3HnG1J9xVB#scrollTo=4805331e

O Anexo I contém um registro da nossa primeira tentativa de modelagem considerando apenas o Aeroporto de Guarulhos. Essa primeira modelagem não foi bem sucedida, pois a rede decorou os dados de treinamento e fracassou na etapa de validação.

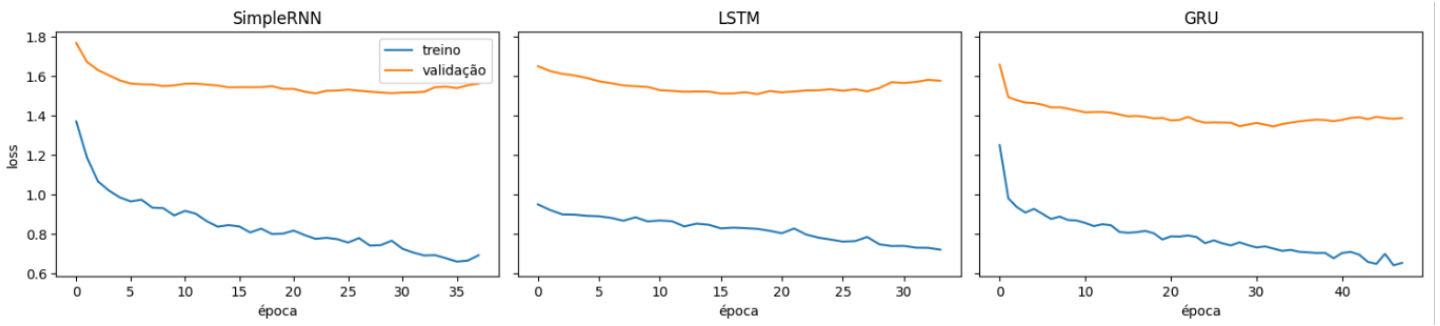
Referências Bibliográficas

1. ANAC - Agência Nacional de Aviação Civil. Dados Abertos: Voo Regular Ativo (VRA), 2025–2026. Disponível em: https://dados.gov.br/dados/conjuntos-dados/voo-regular-ativo-vra.
2. GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. Deep Learning. MIT Press, 2016.
3. Registro de aulas de professor Sérgio Canuto durante a disciplina de Deep Learning no curso PÓS-GRADUAÇÃO LATO SENSU ESPECIALIZAÇÃO EM INTELIGÊNCIA ARTIFICIAL APLICADA (2026/2)

ANEXO I

Primeira Rede Neural com apenas o Aeroporto de Guarulhos nos meses de 01/2026 e 02/2026 fracassou

Conforme pode ser observado na Figura abaixo, a rede não conseguiu aprender.



Inicialmente, realizou-se um experimento restrito a dois meses de dados de um único aeroporto (Guarulhos), cujos resultados evidenciaram a falta de generalização do modelo, conforme ilustrado na perda de treinamento e validação. Uma possível causa dessa limitação ocorreu porque os atrasos na aviação civil propagam-se em cascata entre os terminais - de modo que atrasos em um aeroporto afetam diretamente os demais. Para capturar adequadamente essa dinâmica de rede e garantir a estabilidade do aprendizado, a estratégia foi expandida para englobar o conjunto completo de aeroportos com uma massa de dados histórica de 12 meses.

O código relativo a essa primeira rede está registrado no seguinte link do Google Colab:

- https://colab.research.google.com/drive/1B1BYDwXB1Wsrxw2zQsSkqUQ5oVHhXiy2